

降维（一）

矩阵降维后可以用更小规模的矩阵表示原矩阵，且不改变原矩阵的特征。在主成分分析（PCA）中，分析特征值和特征值的使用。本文介绍奇异值分解（SVD），一种比UV分解更强大的分解。然后在SVD的基础上介绍它的变种，CUR分解，CUR分解可以在原矩阵是稀疏时，保持分解后矩阵的稀疏性的分解方式。

基础概念

欧氏空间

定义了内积的实数域上的向量空间，称为欧几里得空间。

奇异矩阵

方阵 A 的秩不是满秩，则 A 是奇异矩阵。

1. 可逆矩阵是非奇异矩阵，非奇异矩阵也是可逆矩阵。
2. 如果 A 为奇异矩阵，则 $Ax = 0$ 有无穷解， $Ax = b$ 有无穷解或者无解。
3. 如果 A 为非奇异矩阵，则 $Ax = 0$ 有且只有唯一0解， $Ax = b$ 有唯一解。

正定矩阵

1. 一个矩阵半正定当且仅当它的每个特征值大于或者等于0。
2. 一个矩阵正定当且仅当它的每个特征值都大于0。

向量范数

1. 非负性： $\|x\| \geq 0$
2. 齐次性： $\|ax\| = |a| \cdot \|x\|$
3. 三角不等式： $\|x\| + \|y\| \geq \|x + y\|$
4. 1-范数： $\|x\|_1 = |x_1| + |x_2| + \dots + |x_n| = \sum_{i=1}^n |x_i|$
5. 2-范数（Euclidean范数）： $\|x\|_2 = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2} = (\sum_{i=1}^n x_i^2)^{\frac{1}{2}}$
6. 无穷范数： $\|x\|_\infty = \max(|x_1|, |x_2|, \dots, |x_n|)$

矩阵范数

如果满足范数三条件，同时满足矩阵乘法相容性（次乘性）： $\|A\| \cdot \|B\| \geq \|A \cdot B\|$

1. 列和范数（1-范数）： $\|A\|_1 = \max_{1 \leq j \leq n} (\sum_{i=1}^m |a_{ij}|)$
2. 行和范数（ ∞ -范数）： $\|A\|_\infty = \max_{1 \leq i \leq m} (\sum_{j=1}^n |a_{ij}|)$
3. Frobenius范数（F-范数）： $\|A\|_F = (\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2)^{\frac{1}{2}}$
4. 2-范数（谱模）： $\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}$ ，矩阵 $A^T A$ 的最大特征值开平方根。

矩阵的乘法表达

设矩阵乘法 $C_{m \times k} = A_{m \times n} B_{n \times k}$

行列相乘

$$c_{ij} = a_i \cdot b_j \quad (1)$$

列行相乘

$$\begin{aligned} AB &= (a_1 \quad a_2 \quad \dots \quad a_n) \cdot \begin{pmatrix} b_1 \\ b_2 \\ \dots \\ b_n \end{pmatrix} = a_1 b_1 + a_2 b_2 + \dots + a_n b_n \\ &= \begin{pmatrix} a_{11} b_{11} & a_{11} b_{12} & \dots & a_{11} b_{1k} \\ a_{21} b_{11} & a_{21} b_{12} & \dots & a_{21} b_{1k} \\ \dots & \dots & \dots & \dots \\ a_{m1} b_{11} & a_{m1} b_{12} & \dots & a_{m1} b_{1k} \end{pmatrix} + \dots + \begin{pmatrix} a_{1n} b_{n1} & a_{1n} b_{n2} & \dots & a_{1n} b_{nk} \\ a_{2n} b_{n1} & a_{2n} b_{n2} & \dots & a_{2n} b_{nk} \\ \dots & \dots & \dots & \dots \\ a_{mn} b_{n1} & a_{mn} b_{n2} & \dots & a_{mn} b_{nk} \end{pmatrix} \end{aligned} \quad (2)$$

行行相乘

$$C = AB = \begin{pmatrix} a_1 \\ a_2 \\ \dots \\ a_m \end{pmatrix} \cdot \begin{pmatrix} b_1 \\ b_2 \\ \dots \\ b_n \end{pmatrix} \quad (3)$$

考虑C的每一个行向量

$$c_i = a_i \cdot \begin{pmatrix} b_1 \\ b_2 \\ \dots \\ b_n \end{pmatrix} = a_{i1} b_1 + a_{i2} b_2 + \dots + a_{in} b_n \quad (4)$$

矩阵C的每一个行向量，是B的行向量的一个线性组合，该线性组合中的系数是 a_i 的各个元素。从这个角度说C的每一个行向量都存在于B的行向量空间内。

列列相乘

$$C = AB = (a_1 \quad a_2 \quad \dots \quad a_n) \cdot (b_1 \quad b_2 \quad \dots \quad b_k) \quad (5)$$

考虑C的每一个列向量

$$c_i = (a_1 \quad a_2 \quad \dots \quad a_n) \cdot b_i = b_{i1} a_1 + b_{i2} a_2 + \dots + b_{in} a_n \quad (6)$$

矩阵C的每一个列向量，是A的列向量的一个线性组合，该线性组合中的系数是 b_i 的各个元素。从这个角度说C的每一列都存在于A的列向量空间内。

特征值和特征向量

定义

设定 M 为一个方阵，设定 λ 为一个常数， e 是一个非零列向量，和 M 的行数相同，那么称 λ 为 M 的特征值， e 为 M 的特征向量。如果 e 是 M 的特征向量， c 是任意常数，那么 ce 也是一个 M 的特征向量，且有相同的特征值。向量乘以一个常量只改变向量的长度，不改变向量的方向，因此为了避免长度的不同，规定单位向量，意味着**向量每个元素的平方和为1**。为了防止出现乘以-1的情况，我们要求特征向量的第一个非零分量为正。

Example 11.1: Let M be the matrix

$$\begin{bmatrix} 3 & 2 \\ 2 & 6 \end{bmatrix}$$

One of the eigenvectors of M is

$$\begin{bmatrix} 1/\sqrt{5} \\ 2/\sqrt{5} \end{bmatrix}$$

and its corresponding eigenvalue is 7. The equation

$$\begin{bmatrix} 3 & 2 \\ 2 & 6 \end{bmatrix} \begin{bmatrix} 1/\sqrt{5} \\ 2/\sqrt{5} \end{bmatrix} = 7 \begin{bmatrix} 1/\sqrt{5} \\ 2/\sqrt{5} \end{bmatrix}$$

demonstrates the truth of this claim. Note that both sides multiply to

$$\begin{bmatrix} 7/\sqrt{5} \\ 14/\sqrt{5} \end{bmatrix}$$

Also observe that the eigenvector is a unit vector, because $(1/\sqrt{5})^2 + (2/\sqrt{5})^2 = 1/5 + 4/5 = 1$. \square

计算特征值和特征向量

1. 幂迭代法

等待更新

2. 行列式为0

由 $Me = \lambda e$, 可得 $(M - \lambda I)e = 0$

即 $M - \lambda I = 0$

该行列式为 n 次, 因此有 n 个解, 从这 n 个解中, 可以求出特征向量 $Me = ce$, 并将 e 调整为单位向量。

通过幂迭代找到特征对 (特征值 + 特征向量)

待完善

矩阵特征向量

对于方阵 M 的列特征向量 e_1, e_2, \dots, e_n , 构造矩阵 E , 其中 E 的第 i 列是 e_i , 那么有 $EE^T = E^T E = I$ 。因为矩阵的特征向量是正交的, 这些是正交的单位向量。

主成分分析 (PCA)


简单来说, 主成分分析是为了找到高维矩阵的主特征值, 通过该特征向量来表示高维矩阵的特征的方法。

参考链接: 如何通俗易懂地讲解什么是 PCA 主成分分析? - 论智的回答 - 知乎 <https://www.zhihu.com/question/41120789/answer/474222214>

如果不想清楚原理, 下面的文章给出了应用计算的例子:

<https://blog.csdn.net/zhongkelee/article/details/44064401>

书中同样给出一个简单例子，如下：



上图是一个二维点集，该二维点集对应的矩阵为（第一列为x坐标，第二列为y坐标）

$$M = \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 3 & 4 \\ 4 & 3 \end{bmatrix}$$

计算 $M^T M$ ，得到

$$M^T M = \begin{bmatrix} 1 & 2 & 3 & 4 \\ 2 & 1 & 4 & 3 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 3 & 4 \\ 4 & 3 \end{bmatrix} = \begin{bmatrix} 30 & 28 \\ 28 & 30 \end{bmatrix}$$

计算特征值为 $\lambda = 58, \lambda = 2$ ，则特征向量为 $\begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$ 和 $\begin{bmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$ ，这里第一个分量选择负值是为了后续的坐标变换更简单。


矩阵 $M^T M$ 的特征向量矩阵为

$$E = \begin{bmatrix} 1\sqrt{2} & -1\sqrt{2} \\ 1\sqrt{2} & 1\sqrt{2} \end{bmatrix}$$


正交向量组成的矩阵可以看成是欧几里得空间的沿轴的旋转，上图的矩阵可以看作是45°逆时针旋转。例如处理矩阵 M 后，

$$ME = \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 3 & 4 \\ 4 & 3 \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} & -1/\sqrt{2} \\ 1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix} = \begin{bmatrix} 3/\sqrt{2} & 1/\sqrt{2} \\ 3/\sqrt{2} & -1/\sqrt{2} \\ 7/\sqrt{2} & 1/\sqrt{2} \\ 7/\sqrt{2} & -1/\sqrt{2} \end{bmatrix}$$

对应的第一个特征向量如下图虚线所示



此时点 $[1, 2]$ 转化为 $[3/\sqrt{2}, 1/\sqrt{2}]$ ，新坐标系的y轴和虚线垂直，如图



使用特征向量降维

1. 通过上例可知，如果矩阵 M 的每一行代表欧几里得空间的一个点，则可以计算 $M^T M$ 然后计算特征向量和特征值，定义矩阵 E 的每一列为对应的特征向量，按照大的特征值对应的特征向量排列。定义矩阵 L 是矩阵 $M^T M$ 的特征值在主对角线按照从大到小的顺序排列，其他位置为0的矩阵，由于对每一个特征向量 e 和特征值 λ 有 $M^T M e = \lambda e = e \lambda$ ，可以得出 $M^T M E = E L$ 。
2. 矩阵 ME 表示矩阵 M 中的点转化到一个新的坐标系空间中，该空间中最主要的轴对应特征值最大的轴，第二个轴对应的则是特征值次大的轴，以此类推。如果想要将矩阵 M 转化到空间维度更小的空

间中，保留相关性最大的特征值（即最大的特征值）对应的轴，并依次选择，忽视特征值很小的轴（维度）。

3. 假如 E_k 表示矩阵 E 的前 k 列，那么 ME_k 则表示矩阵 M 的一个 k 维表达。

例：

考虑上图中的例子，由于原坐标系只有2维，因此只能降为1维，因此计算 ME_1 如下，

$$\begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 3 & 4 \\ 4 & 3 \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{bmatrix} = \begin{bmatrix} 3/\sqrt{2} \\ 3/\sqrt{2} \\ 7/\sqrt{2} \\ 7/\sqrt{2} \end{bmatrix}$$

新矩阵代替了原矩阵，此时所有的点都被虚线上的投影代替，尽管前两个点（后两个点）的投影相同，这样的投影表达了在一维情况下对 M 中点的最好的分割。

矩阵的距离

考虑 MM^T 的特征值，因为 M 的行数多于列数，因此 MM^T 的大小要比 $M^T M$ 大，但是如果 M 的列数多于行数，反而 $M^T M$ 的大小会更大。如图，

$$MM^T = \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 3 & 4 \\ 4 & 3 \end{bmatrix} \begin{bmatrix} 1 & 2 & 3 & 4 \\ 2 & 1 & 4 & 3 \end{bmatrix} = \begin{bmatrix} 5 & 4 & 11 & 10 \\ 4 & 5 & 10 & 11 \\ 11 & 10 & 25 & 24 \\ 10 & 11 & 24 & 25 \end{bmatrix}$$

和 $M^T M$ 一样， MM^T 也是一个对称矩阵，在 $M^T M$ 和 MM^T 的特征值之间有较强的联系，设 e 是 $M^T M$ 的特征向量，则有

$$M^T M e = \lambda e \quad (7)$$

两边乘以 M ，有

$$MM^T (Me) = M\lambda e = \lambda (Me) \quad (8)$$

因此，只要 Me 不是0向量，那么它是 MM^T 的特征向量， λ 既是 $M^T M$ 也是 MM^T 的特征值。该结论对于 MM^T 也适用（不再详细说明）。

当 $M^T e = 0$ 时， $MM^T e = 0$ ，由 $\lambda e = 0$ 可知， $\lambda = 0$ 。

结论： MM^T 的特征值（包括0）也是 $M^T M$ 的特征值，如果 MM^T 的维数小于 $M^T M$ ，那么结论反过来成立。

例：

$$\begin{bmatrix} 3/\sqrt{116} & 1/2 & 7/\sqrt{116} & 1/2 \\ 3/\sqrt{116} & -1/2 & 7/\sqrt{116} & -1/2 \\ 7/\sqrt{116} & 1/2 & -3/\sqrt{116} & -1/2 \\ 7/\sqrt{116} & -1/2 & -3/\sqrt{116} & 1/2 \end{bmatrix}$$

上图为 MM^T 的特征向量矩阵， MM^T 的特征向量中包含 $M^T M$ 的特征值58和2，但是因为有4个值，因此剩余的为0。

附注

定理1

实对称矩阵的不同的单位特征向量是正交的。

证明

设矩阵 A 的特征向量 p, q 满足 $Ap = mp, Aq = nq$ ，其中 m, n 为特征值，则有

$$p^T(Aq) = p^T(nq) = np^Tq \quad (9)$$

$$(p^T A)q = (p^T A^T)q = (Ap)^T q = (mp)^T q = mp^T q \quad (10)$$

又 $p^T(Aq) = (p^T A)q$ ，则有

$$(m - n)p^T q = 0 \quad (11)$$

因此 $p^T q = 0$ ，因此 p, q 正交。